

Arquitectura Transformer - Pagina 1

Los Transformers son una arquitectura de red neuronal propuesta en 2017.

Fueron introducidos en el paper Attention is All You Need.

Los autores principales son Vaswani, Shazeer y Parmar.

La arquitectura se basa completamente en mecanismos de atencion.

No utiliza recurrencia ni convoluciones.

Arquitectura Transformer - Pagina 2

El mecanismo de atencion multi-cabeza es el componente central.

Cada cabeza de atencion calcula escalas de producto punto.

Las consultas, claves y valores son proyecciones lineales.

El modelo base tiene 6 capas en el encoder y 6 en el decoder.

El modelo grande tiene 12 capas en cada componente.

Arquitectura Transformer - Pagina 3

Los resultados en traduccion automatica fueron revolucionarios.

En WMT 2014 English-to-German, lograron BLEU de 28.4.

En WMT 2014 English-to-French, lograron BLEU de 41.8.

El modelo base tiene dimension d_{model} de 512.

El modelo grande tiene dimension d_{model} de 1024.